
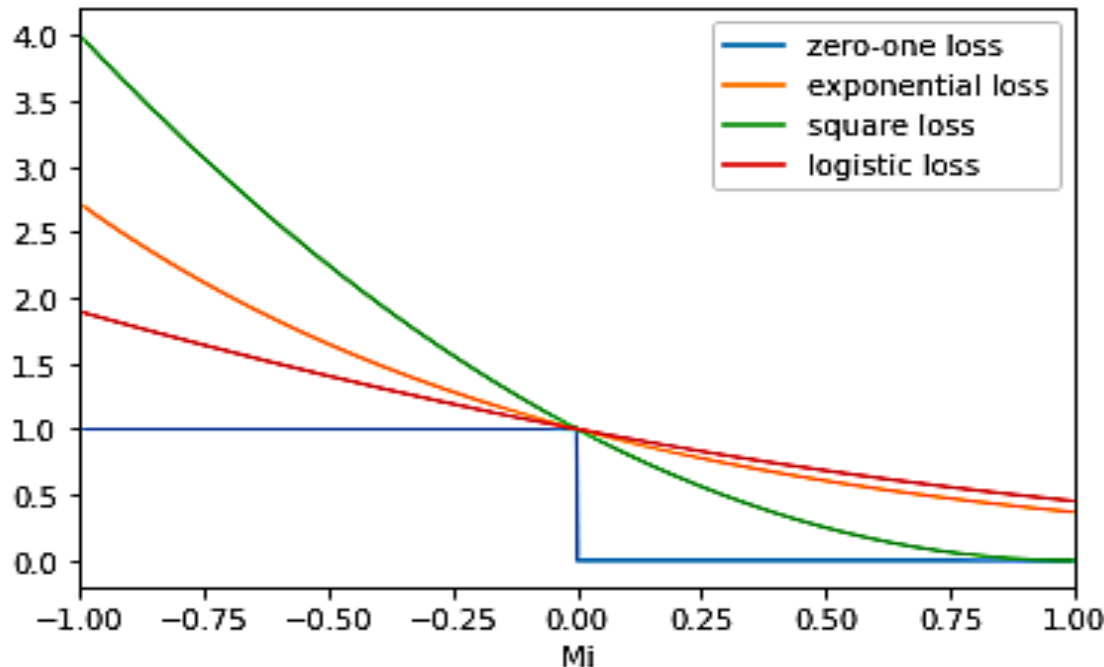


Машины опорных векторов

Корлякова М.О.
2022



Рабочие Потери



$$[M_i < 0] \leq \tilde{L}(M_i).$$

$$Q(a, X) \leq \tilde{Q}(a, X) = \frac{1}{l} \sum_{i=1}^l \tilde{L}(M_i) \rightarrow \min_{\omega}$$

- логарифмическая $\mathcal{L}(M) = \log(1 + e^{-M})$
- кусочно-линейная $\mathcal{L}(M) = (1 - M)_+$
- экспоненциальная $\mathcal{L}(M) = e^{-M}$

Отделимость

1) Непустые выпуклые множества A и B называются (собственно) отделимыми, если существует аффинная гиперплоскость

$$H = \{x \in \mathbb{R}^n \mid v^T x = b\}, \quad v \in \mathbb{R}^n, \quad v \neq 0,$$

такая, что множества A, B лежат в противоположных по отношению к H замкнутых полупространствах и, по крайней мере, одно из множеств A, B не содержится в H . В этом случае гиперплоскость H отделяет множества A, B .

Отделимость

2) Непустые выпуклые множества A и B называются строго отделимыми, если существуют две различные параллельные гиперплоскости

$$H_1 = \{ x \in \mathbb{R}^n \mid v^T x = b_1 \}, H_2 = \{ x \in \mathbb{R}^n \mid v^T x = b_2 \}, v \in \mathbb{R}^n,$$

такие, что



$$\inf_{x \in A} v^T x > b_1 > b_2 > \sup_{x \in B} v^T x.$$

Отделимость

Теорема 1.

Пусть A и B — непустые выпуклые множества в \mathbb{R}^n , $A \cap B = \emptyset$. Тогда множества A и B отделимы.

Линейно-разделимые модели




$$M = y(w^T x - b)$$

Hinge_loss


$$H = \max(0, 1 - y(w^T x))$$

Опорные вектора



C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998


Опорные вектора и поля



$$2/\|w\| \rightarrow \max$$

$$\|w\| \rightarrow \min$$


$$(w^T w)/2 \rightarrow \min$$



Опорные вектора и поля

$$\begin{aligned}\langle (x_+ - x_-), w / \|w\| \rangle &= (\langle x_+, w \rangle - \langle x_-, w \rangle) / \|w\| = \\ &= ((b + 1) - (b - 1)) / \|w\| = 2 / \|w\|\end{aligned}$$

- Для опорных векторов
 $w x_i + b = \pm 1$
- Расстояние от точки до гиперплоскости
 $|x_i w + b| / \|w\|$
- Отступ – поля
 $\rho = 2 / \|w\|$
- **Максимизация полей = минимизация $\|w\|$**



Опорные вектора и поля


Максимизация полей = минимизация $\|w\|$

- Задачей выпуклого программирования называется задача минимизации выпуклой функции на выпуклом множестве


$f: X \rightarrow \mathbb{R}^n$ — выпуклая функция
с областью определения $\text{dom } f = X$.

Выпуклой задачей без ограничений
называется задача

$$\min_{x \in X} f(x).$$



*В выпуклой задаче локальный минимум
всегда будет и глобальным*



Опорные вектора и поля

Максимизация полей = минимизация $\|w\|$


- Задачей выпуклого программирования называется задача минимизации выпуклой функции на выпуклом множестве


$f: X \rightarrow \mathbb{R}^n$ — выпуклая функция
с областью определения $\text{dom } f = X$.

Выпуклой задачей с ограничениями
называется задача

$$\min_{x \in X} f(x).$$

$h_i, i = 1, \dots, p$ — достаточно
гладкие выпуклые функции





Опорные вектора и поля


Максимизация полей = минимизация $\|w\|$


- Задачей выпуклого программирования называется задача минимизации выпуклой функции на выпуклом множестве

$f: X \rightarrow \mathbb{R}^n$ — выпуклая функция
с областью определения $\text{dom } f = X$.

Двойственная функция Лагранжа
для задачи определяется как

$$\begin{aligned}\varphi(v) &= \inf \{x \in Q, L(x, v)\} \\ &= \inf \{x \in Q, (f(x) + \sum \alpha_i h_i(x)), i = 1, p\}\end{aligned}$$





Опорные вектора и поля

Теорема Куно -Такера

Пусть выполняются условия задачи выпуклости.

- Тогда если x^* — решение задачи, то существует ненулевой вектор множителей Лагранжа $\alpha = (\alpha_i)_{i=1,p}$, такой, что для функции Лагранжа

$$L(x, v) = f(x) \alpha_0 + \sum_{i=1,p} \alpha_i h_i(x)$$

Выполняются:

1) принцип минимума для функции Лагранжа

$$\min_{x \in Q} L(x, v) = L(x^*, \alpha);$$

$$x \in Q$$

2) условия дополняющей нежёсткости


$$\alpha_i h_i(x^*) = 0, i = 1, \dots, p;$$

3) условия неотрицательности

$$\alpha_i \geq 0, i = 0, \dots, p;$$

Если $\alpha_0 \neq 0$, то условия 1) – 3) предыдущего утверждения достаточны для того, чтобы допустимая точка x^* была решением задачи

Опорные вектора и поля



Линейное программирование :


Задача минимизации линейной формы при линейных ограничениях

Джордж Стиглер, возникла в американской армии в 30–40-е годы XX века.
Задача о диете:

выбрать суточный набор продуктов питания минимальной стоимости, который будут обеспечивать необходимую норму питательных веществ.

В 1940 г. Л. В. Канторович опубликовал статью «Об одном эффективном методе решения некоторых классов экстремальных проблем»

Д. Данциг (1914–2005) в 1947 г. разработал первый вычислительный алгоритм для решения задач ЛП — симплекс-метод



Опорные вектора и поля

Задача квадратичного программирования:

Задача минимизации квадратичной формы при линейных ограничениях


$$\begin{aligned} x^T C x + d^T x &\rightarrow \min \\ Ax &\geq b \end{aligned}$$

Функция Лагранжа:

$$L(x, v) = x^T C x + d^T x + \alpha^T (Ax - b).$$

Двойственная функция:

$$\varphi(v) = \inf_x L(x, v).$$



Опорные вектора и поля

Задача квадратичного программирования:


Необходимым и достаточным условием экстремума при $C > 0$ в точке x^* , $Ax^* \leq b$ является существование

$$\alpha^* \in \mathbb{R}^m, \alpha^* \geq 0 \text{ таких, что}$$
$$2Cx^* + d + A^T\alpha^* = 0, \langle \alpha^*, Ax^* - b \rangle = 0.$$

Кроме того, при $C > 0$ двойственная задача для задачи квадратичного программирования :

$$\min_{\alpha \geq 0} 1/4(C^{-1}(-d - A^T\alpha))^T(-d - A^T\alpha) + b^T\alpha$$

В случае $C > 0$ для прямой и двойственной задач выполняется свойство сильной двойственности, т.е. оптимальные значения прямой и двойственной задач квадратичного программирования совпадают



Прямая задача оптимизации


- $\min \Phi(w) = 1/2 w^T w$ по w
при $d_i(w^T x_i + b) \geq 1$

$$J(w, b, \alpha) = 1/2 w^T w - \sum \alpha_i (d_i (w^T x_i + b) - 1)$$

Условие оптимальности:

$$\frac{\partial J(w, b, \alpha)}{\partial w} = 0 \Rightarrow \frac{\partial J(w, b, \alpha)}{\partial w} = w - \sum_{i=1}^N \alpha_i d_i x_i = 0$$


$$\frac{\partial J(w, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$




Решение

- $W = \sum \alpha_i y_i x_i$
 - x_i – опорные вектора
 - α_i – обученные веса
- Для большей части векторов вес = 0!
- Все вектора, для которых вес > 0 называются опорными
- Определяется только опорными векторами


Решение задачи оптимизации для линейно-разделимых образов




Линейно-разделимые образы



Расстояние от плоскости



Двойственная задача оптимизации




N N

$\max Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$ при условии:

- $\sum_{i=1}^N \alpha_i d_i = 0$
- $0 \leq \alpha_i$

$$\mathbf{w}_0 = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i,$$

$$b_0 = 1 - \mathbf{w}_0^T \mathbf{x}_s$$



Статистические свойства


$$h \leq \min \left\{ \left\lceil \frac{D^2}{\rho^2} \right\rceil, m_0 \right\} + 1$$

D – диаметр наименьшего шара

ρ - граница


h – VCdim оптимальной гиперплоскости


m_0 – размерность входного пространства



Задача оптимизации

- Нелинейное пространство примеров
- $\{(x_i, d_i)\}$







- $d_i(w^T x_i + b) - \xi_i, \quad i=1, N$
- $0 \leq \xi_i \leq 1$ – верная классификация
- $\xi_i > 1$ – ошибки

• Опорные вектора

Для $\xi_i > 0$


$$d_i(w^T x_i + b) = 1 - \xi_i$$






$$\begin{cases} (w^T w)/2 + \alpha \sum \xi_i \rightarrow \min \\ y(w^T x_i - b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

$$Penalty = \sum [M_i < 0]$$



$$[M_i < 0] = \begin{cases} 1 & , \text{если } M_i < 0 \\ 0 & , \text{если } M_i \geq 0 \end{cases}$$

$$Penalty = \sum [M_i < 0] \leq \sum (1 - M_i)_+ = \sum \max(0, 1 - M_i)$$




Задача оптимизации

- $\min \Phi(\xi) = \sum I(\xi_i - 1)$ по w при $d_i(w^T x_i + b) \geq 1 - \xi_i$
- $I(\xi_i - 1)$ – индикатор
 - $I(\xi_i - 1) = 0$ при $\xi_i \leq 1$
 - $I(\xi_i - 1) = 1$ при $\xi_i > 1$

$\Phi(\xi) = \sum I(\xi_i - 1)$ аппроксимируем

$$\Phi(w, \xi) = 1/2 w^T w + C \sum \xi_i, \text{ где } i=1, N$$



Прямая задача оптимизации


- $\{(\chi_i, d_i)\}$, где $i=1, N$

$$\min \Phi(\xi, w) = 1/2 w^T w + C \sum \xi_i,$$

При ограничениях :

- $\xi_i \geq 0$
- $d_i(w^T \chi_i + b) \geq 1 - \xi_i$
- $C > 0$

Двойственная задача ОПТИМИЗАЦИИ



N N

- $\max Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \chi_i^T \chi_j$ при условии:


- $\sum \alpha_i d_i = 0$
- $0 \leq \alpha_i \leq C$
- $C > 0$

$w_0 = \sum \alpha_{0i} d_i \chi_i$, где вектора χ_i опорные

Отбор опорных векторов

$$(\alpha_{0i}(d_i(w^T \chi_i + b) - 1 + \xi_i) = 0)$$


$$0 < \alpha_i < C$$




Разработка SVM систем

- Перейти к линейной модели большей размерности.
- Построить гиперплоскость.

Теорема Ковера




- Условия
 - Преобразование нелинейно
 - Размерность нового пространства большая



Поиск преобразования

- Вычисление скалярных произведений в многомерном пространстве вычислительно сложно
- вместо прямого вычисления преобразования $\phi(x)$, определим ядро скалярного произведения $K(x, x_i) = \phi(x)^T \phi(x_i)$
- ядро должно удовлетворять условию Мерсера (*Mercer's condition*)
 - Матрица $K(x_i, x_j)$ должна быть неотрицательно определенной

Ядро скалярного произведения



$$\left\{ \phi_j(x) \right\}_{j=1}^{m1}$$

$$\sum_{j=1}^{m1} w_j \phi_j(x) + b = 0$$

$$\phi_0(x) = 1, w_0 = b \Rightarrow \sum_{j=0}^{m1} w_j \phi_j(x) = 0$$


$$\bar{\phi}(x) = \left[\phi_0(x) \dots \phi_{m1}(x) \right]^T$$

$$W^T \bar{\phi}(x) = 0$$

$$w = \sum_{i=1}^N \alpha_i d_i \bar{\phi}(x_i)$$


$$\sum_{i=1}^N \alpha_i d_i \bar{\phi}^T(x_i) \bar{\phi}(x_i) = 0$$

Ядро скалярного произведения





- $K(\mathbf{x}\mathbf{x}_i) = \varphi(\mathbf{x})^\top \varphi(\mathbf{x}_i) = \sum_{j=0}^{m-1} \varphi_j(\mathbf{x}) \varphi_j(\mathbf{x}_i) \quad j=0..m-1, i=1..N$


$$\sum \alpha_i d_i K(\mathbf{x}\mathbf{x}_i) = 0$$



Использование ядра

- Выбрать признаки
- Выбрать ядро для этого вектор-признака
- Вычислить матрицу значений ядра для каждой пары примеров из обучающей выборки
- применить SVM для получения весов и опорных векторов

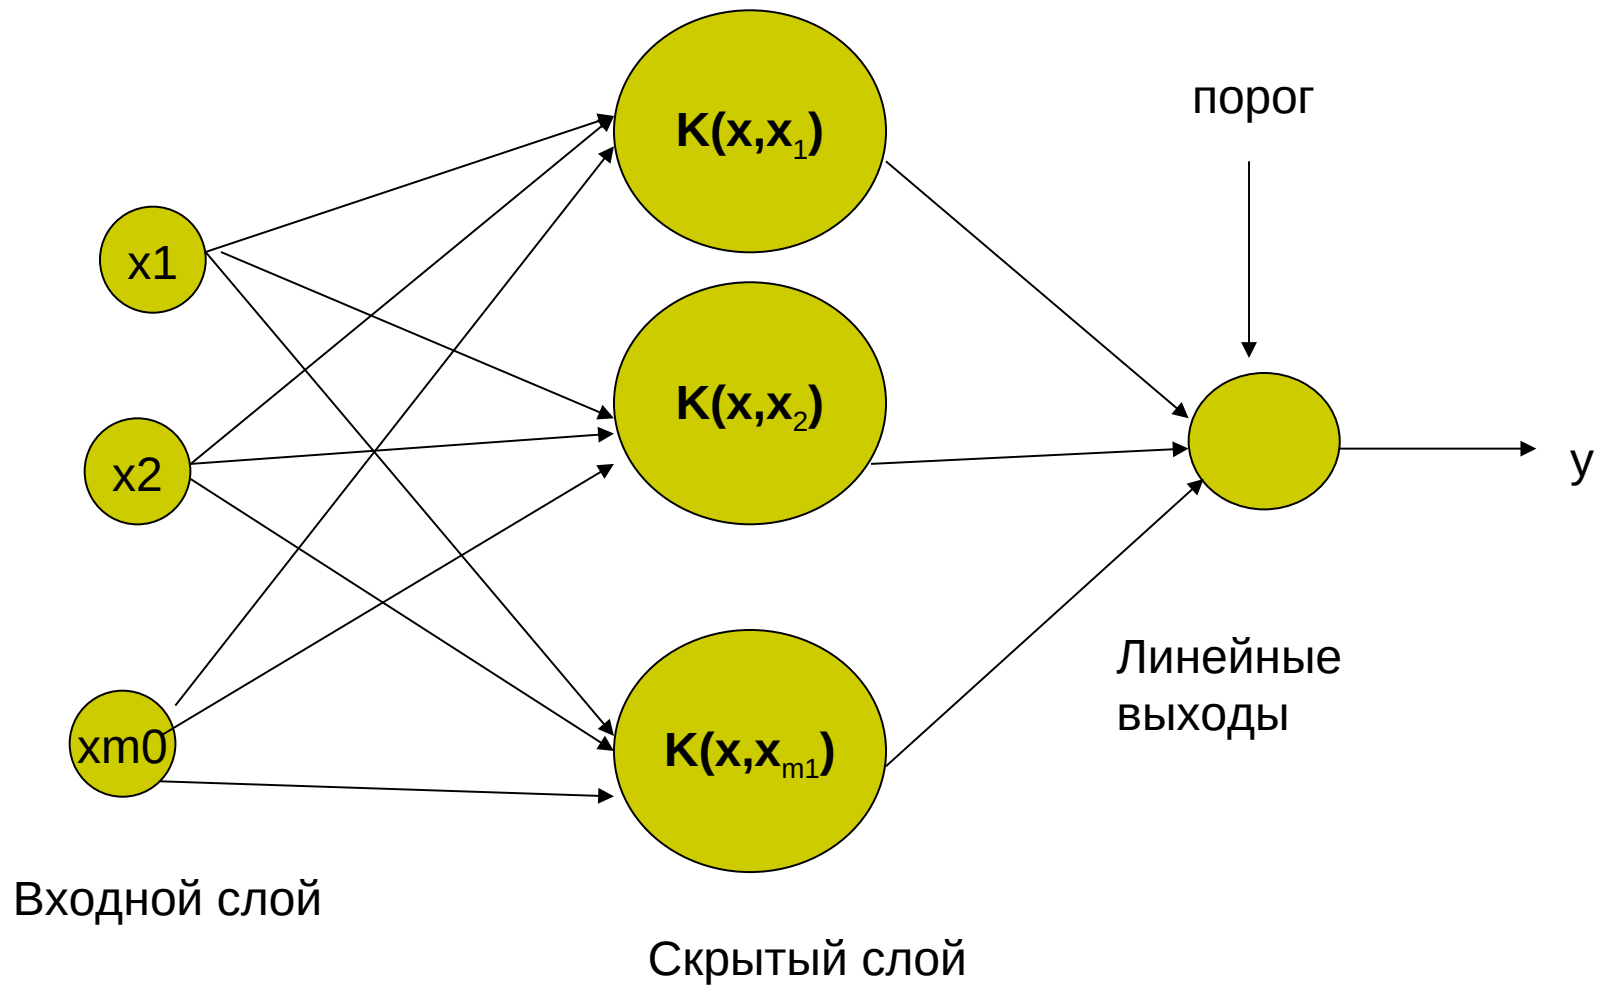






Примеры SVM

Тип SVM	ядро	
полиномиальные	$(\mathbf{x}^T \mathbf{x}_j + 1)^p$	
Сети RBF	$\exp(-1/(2\sigma^2) \ \mathbf{x} - \mathbf{x}_j\ ^2)$	
2-й перцептрон	$\text{Th}(\beta_0 \mathbf{x}^T \mathbf{x}_j + \beta_1)$	


Модель SVM




XOR



- x_1 x_2 d
- \mathbf{x}_1 -1 -1 -1
- \mathbf{x}_2 -1 +1 +1
- \mathbf{x}_3 +1 -1 +1
- \mathbf{x}_4 +1 +1 -1



- $K(x, x_i) = |1 + x^T x_i|^2$
- $x = [x_1, x_2]^T$
- $x_i = [x_{i1}, x_{i2}]^T$
- $K(x, x_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_{i1} x_2 x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$




- $\varphi(\mathbf{x}) = [1, x_1^2, \sqrt{2} x_1 x_2, x_2^2, \sqrt{2} x_1, \sqrt{2} x_2]$
- $\varphi(\mathbf{x}_i) = [1, x_{1i}^2, \sqrt{2} x_{1i} x_{2i}, x_{2i}^2, \sqrt{2} x_{1i}, \sqrt{2} x_{2i}]$

ядро



$$K = \begin{pmatrix} & 9 & 1 & 1 & 1 \\ 1 & 9 & 1 & 1 & \\ & 1 & 1 & 9 & 1 \\ & & 1 & 1 & 1 & 9 \end{pmatrix}$$



Целевая функция

- $Q(a) = a_1 + a_2 + a_3 + a_4 - \frac{1}{2} (9 a_1^2 - 2 a_1 a_2 - 2 a_1 a_3 + 2 a_1 a_4 + 9 a_2^2 + 2 a_2 a_3 - 2 a_2 a_4 - 9 a_3^2 - 2 a_3 a_4 + 9 a_4^2)$


- система

$$9 a_1 - a_2 - a_3 = a_4 = 1$$

$$- a_1 = 2 a_2 = a_3 - a_4 = 1$$

$$- a_1 = a_2 = 9 a_3 - a_4 = 1$$



$$a_1 - a_2 - a_3 = 9 a_4 = 1$$




Множители Лагранжа

- $a_1 = a_2 = a_3 = a_4 = 1/8$
- $a_i > 0$ - все примеры опорные

сеть







Нелинейная регрессия

- $L_\varepsilon(d, y) = \begin{cases} |d - y| - \varepsilon & \text{при } |d - y| > \varepsilon \\ 0 & \text{иначе} \end{cases}$
- $d_i - w^T \varphi(x_i) \leq \varepsilon + \xi_i$
- $w^T \varphi(x_i) - d_i \leq \varepsilon + \xi_i'$

SVM



- Плюсы
 - Много доступных библиотек:
<http://www.kernel-machines.org/software>
 - Мощный и гибкий подход на основе ядер
 - Работает хорошо, даже для маленьких обучающих выборок
- Минусы
 - Нет прямых многоклассовых методов, нужно объединять двухклассовые
 - Вычисления, память
 - При обучении нужно строить полную матрицу ядра для всех примеров
 - Обучение занимает много времени для больших задач



литература

- Математические методы распознавания образов. Курс лекций. МГУ, ВМиК, кафедра «Математические методы прогнозирования» Местецкий Л.М., 2002–2004
- Хайкин С. Нейрокомпьютеры: полный курс. – М.:Вильямс – 2006 (стр 418-435)