




Статистическая природа обучения

Корлякова М.О.
2018




Оценка классификатора






VC - измерение

- ограничение на скорость сходимости
- измерение Вапника-Червоненкиса (1971)
- мера емкости (вычислительной мощности) семейства функций классификации, реализованных обучаемыми машинами.




Определение VC

- VC-измерением классификатора F называют мощность наибольшего множества L , разбиением которого является F .
- VC-измерение комбинаторно




двоичная классификация


- $d=\{0,1\}$
- правило $F(\mathbf{x},w)$ – i -я дихотомия
- множество дихотомий, реализованных обучаемой машиной
$$F = \{F(\mathbf{x},w) : w \in W, F: \mathbb{R}^m W \rightarrow \{0,1\}\}$$
- $L = \{\mathbf{x}_i \in X: i=1..N\}$ – точки m -мерного пространства



- дихотомия делит L на $L1$, $L0$




$$F(x, w) = \begin{cases} 0 & \text{для } x \in L0 \\ 1 & \text{для } x \in L1 \end{cases}$$



- $\Delta_F(L)$ - число различных дихотомий
- $\Delta_F(\ell)$ - максимум для $\Delta_F(L)$ всех L , где $|L|=\ell$
- $\Delta_F(\ell)$ - функция роста.

Пример




$$D_0 = \{G_0 = \{x_1, x_2, x_3\}\}, G_1 = \{x_4\}$$

$$D_1 = \{G_0 = \{x_2, x_3, x_4\}\}, G_1 = \{x_1\}$$

$$|L| = 4$$

$$\Delta_F(L) = 16$$

$$\Delta F(\ell) = 3$$




Функция роста

- $\Delta_F(\ell) \equiv 2^{|\ell|}$


или

- мажорируется $\Delta_F(\ell) \leq 1.5 \ell^n / n!$
- $n+1$ минимальный объем выборки для которого нарушено условие $2^{|\ell|}$




Определения VC

- VC-измерением $F(x, w)$ называют мощность наибольшего множества L , разбиением которого является $F(x, w)$
- VC-измерение комбинаторно



Скорость сходимости

- $R(w)$ – функционал риска – вероятность ошибка классификатора.
- $R_{\text{emp}}(w)$ – функционал эмпирического риска – частота ошибка.
- При $N \rightarrow \infty$, $R_{\text{emp}}(w) \rightarrow R(w)$




Доверительный интервал

- Связь ошибки обучения, объема выборки и вероятности достижения $|R(w) - R_{emp}(w)| > \varepsilon$ для текущей модели.
- $R(w) < R_{emp}(w) + \varepsilon$

$$\varepsilon_0(N, h, a) = 2 \left(\frac{h}{N} \times [\log(2 \times N/h) + 1] - \frac{1}{N} \times \log a \right)$$

$$\varepsilon_1(N, h, a, R_{emp}) = 2 \times \varepsilon_0^2(N, h, a) \times \left(1 + \sqrt{(1 + R_{emp}(w) / \varepsilon_0^2(N, h, a))} \right)$$


Если $R_{emp}(w) = 0$, $\varepsilon_1(N, h, a, R_{emp}) = 4 * \varepsilon_0^2(N, h, a)$



Скорость сходимости


- Ограничение 1 (общий случай)
 $R(w) \leq R_{emp}(w) + \varepsilon 1(N, h, a, R_{emp})$
- Ограничение 2 (при малой величине $R_{emp}(w)$)
 $R(w) \leq R_{emp}(w) + 4\varepsilon 0(N, h, a)$
- Ограничение 3 (для большой $R_{emp}(w)$)
 $R(w) \leq R_{emp}(w) + \varepsilon 0(N, h, a)$

Резюме



	малая емкость класс $F(X,W)$	большая емкость класс $F(X,W)$
Близость эмпирического правила к оптимальному	хорошая	плохая
Качество разделения	низкое	высокое

Минимизация структурного риска





Гарантированный риск


$$R_{\text{guarant}}(w) = R_{\text{emp}}(w) + \varepsilon 1(N, h, a, R_{\text{emp}})$$

- h – VC измерение классификатора F
- N – число примеров для обучения
- $\varepsilon 1$ – доверительный интервал


R_{gene} – ошибка обобщения




Требование к обучению с учителем.



- Необходимо привести в соответствие объем классификатора и объем выборки.




- Рассмотрим
- $F_k = \{F(\mathbf{X}, \mathbf{w}); \mathbf{w} \in W\} \quad k=1, 2, \dots, n$
- $F_1 \subset F_2 \subset \dots \subset F_n$
- $h_1 \leq h_2 \leq \dots \leq h_n$




Пример

- 3000 примеров для обучения и 3000 для теста
- Определена средняя ошибка обобщения по 10 перезапускам
- Число настраиваемых параметров 2×3 (5, 7, 9, 11, 13, 15, 17, 19, 22, 24, 26, 27)


Модель множества T



Результаты моделирования




Метод минимизации структурного риска



- Минимизируем R_{emp} для каждого классификатора.
- Определяем F^* , который имеет наименьший $R_{guarant}(w)$




Резюме:




Процесс обучения

- Обучение с учителем $T=\{(X_i, Y_i)\}$
- Обучение без учителя $T=\{(X_i)\}$




- ψ - стохастическое явление, где X случайный вектор из n независимых переменных
- Случайный скаляр D – зависимая переменная
- Представлено N реализаций – примеров вектора X , - $\{X_i\}$, $i=1.N$ и соответствующих им значений случайного скаляра D , $\{d_i\}$

Обучающая выборка





- $T = \{(X_i, d_i)\}, \quad i=1..N$


Регрессионная модель связи X и D



- $D = f(X) + \varepsilon$
- ε - ожидаемая ошибка
 - нормально распределена
 - $M(\varepsilon)=0$
- $f(\bullet)$ – детерминированная функция векторного аргумента.

Представление регрессионной модели






Свойства модели

1. Среднее значение ожидаемой ошибки ε для любой реализации X

$$E[\varepsilon|x] = 0$$

следовательно

$$f(x) = E[D|x]$$




Свойства модели

1. **Принцип ортогональности.** Ошибка ε не коррелирует с функцией регрессии $f(X)$

$$E[\varepsilon f(X)] = 0$$



Вся информация о D , доступная через X , закодирована в функции регрессии $f(X)$.

Доказательство:



$$E[\varepsilon f(X)] = E[E[\varepsilon f(X)|x]] = E[f(X) E[\varepsilon|x]] = E[f(X)*0] = 0$$


Физическое представление



- Позволяет закодировать эмпирические знания выборки T , с помощью синаптических весов w

$$T \rightarrow w$$


$$Y = F(X, w)$$



Определение w

- Минимизация функции стоимости
пакетное обучение:

$$Er(w) = \frac{1}{2} \sum (d_i - F(x_i, w))^2,$$




- Т.к. $T \rightarrow w$,

то $F(x, w)$ заменяема на $F(x, T)$,

$$Er(w) = \frac{1}{2} E_T[(d_i - F(x_i, T))^2], \text{ где}$$

$E_T[\bullet]$ – оператор усреднения по T




- $d - F(x, T) = (d - f(x)) + (f(x) - F(x, T)) = \varepsilon + (f(x) - F(x, T)) ,$

- $mozda$


$$Er(w) = \frac{1}{2} E_T[\varepsilon^2] + \frac{1}{2} E_T[(f(x) - F(x, T))^2] + E_T[\varepsilon(f(x) - F(x, T))] , z\partial e$$

$$E_T[\varepsilon (f(x) - F(x, T))]=0$$




- $Er(w) = \frac{1}{2} E_T[\varepsilon^2] + \frac{1}{2} E_T[(f(x) - F(x, T))^2]$
- $E_T[\varepsilon^2]$ – дисперсия ожидаемой ошибки (регрессионной) вычисляемой на T .
- ε - исходная $\Rightarrow$ не зависит от w , а значит ее можно не учитывать, т.к. $Er(w)$
- $E_T[(f(x) - F(x, T))^2]$ – среднее по ансамблю расстояние от $f(x)$ к $F(x, T)$

Функция стоимости для построения w




- $Er(w) = \frac{1}{2} E_T[(f(x) - F(x, T))^2]$

Мера прогнозирования




$$L_{av}(f(x), F(x, T)) = E_T[(f(x) - F(x, T))^2]$$



$$f(x) = E[D|x]$$

$$L_{av}(f(x), F(x, T)) = E_T[(E[D|X=x] - F(x, T))^2] \quad (1)$$

*Ошибка оценивания регрессионной
функции $f(X)$ аппроксимационной $F(x, T)$*




$$(E[D|X=x] - F(x, T)) = (E[D|X=x] - E_T[F(x, T)]) + (E_T[F(x, T)] - F(x, T)) \quad (2)$$

Тогда

$$L_{av}(f(x), F(x, T)) = E_T[(E[D|X=x] - F(x, T))^2] = B^2(w) + V(w) \quad (3)$$

$B(w) = E_T [(E[D|X=x] - F(x, T))]$ – смещение среднего для $F(x, T)$ относительно $f(x) \Rightarrow$ **ошибка аппроксимации**

$V(w) = E_T [(E_T[F(x, T)] - F(x, T))^2]$ – **дисперсия** $F(x, T)$ на всем T .



Ошибка аппроксимации

Исходная ошибка
 $\varepsilon = d - f(X)$

$E_T[F(x, T)]$

$F(x, T)$


d

$f(x) = E[D|x]$


Функции входа
 x

$(\text{Смещение}^2 + \text{дисперсия})^{1/2}$


Дилемма смещения/дисперсии



- Одновременно уменьшить смещение и дисперсию можно только для бесконечно большой выборки





Теория статистического обучения.




Объем выборки

- Объем выборки должен быть адекватным
- Каким?


Модель обучения с учителем





Обучение с учителем

- Выбор конкретной $F(x, w)$, который оптимально аппроксимирует отклик d , где выбор основан на N независимых, равномерно распределенных примерах.
- $T = \{(X_i, d_i)\}, \quad i=1..N$



Мера потерь


пусть

$L(d, F(x, w))$ – мера потерь или несходства между желаемым откликом d на вектор x и $F(x, w)$

$$L(d, F(x, w)) = (d_i - F(x_i, T))^2$$


$L_{av}(f(x), F(x, T)) = E_T[(f(x) - F(x, T))^2]$ – мера прогнозирования

Ожидаемая величина потерь



- $R(w) = \int L(d, F(x, w)) d F_{x,D}(x, d) \quad (6)$
- Цель обучения с учителем минимизация функционала риска $R(w)$ в классе функций аппроксимации $F(x, w)$.
- $F_{x,D}(x, d)$ обобщенная функция распределения


Принцип минимизации эмпирического риска




- $R_{\text{emp}}(w) = 1/N \sum L(d_i, F(x_i, w))$, $i=1..N$ (7)

Достоинства:


- Не зависит от распределения $F_{x,D}(x,d)$
- Можно минимизировать по w



- w_{emp} и $F(x, w_{\text{emp}})$ – соответствуют минимуму функционала $R_{\text{emp}}(w)$
- w_0 и $F(x, w_0)$ - соответствуют минимуму функционала $R(w)$
- w_{emp} и $w_0 \in W$
- Найти условия, при которых $F(x, w_{\text{emp}})$ близко к $F(x, w_0)$
- Мера близости разница между $R_{\text{emp}}(w)$ и $R(w)$




- Если $R_{\text{emp}}(w)$ аппроксимирует $R(w)$ равномерно с точностью ε , то их минимумы отстоят друг от друга не более чем на 2ε
- $P(\sup | R(w) - R_{\text{emp}}(w) | > \varepsilon) \rightarrow 0 \text{ } N \rightarrow \infty$
- $P(\sup | R(w) - R_{\text{emp}}(w) | > \varepsilon) < a \quad (8)$
- $P((R(w_{\text{emp}}) - R(w_0)) > 2\varepsilon) < a \quad (9)$



- $R(w_{\text{emp}}) - R_{\text{emp}}(w_{\text{emp}}) < \varepsilon \quad (10)$

- $R_{\text{emp}}(w_0) - R(w_0) < \varepsilon$

- $R_{\text{emp}}(w_{\text{emp}}) - R(w_0) < 2\varepsilon \quad (11)$



Принцип минимизации эмпирического риска

1

$R(w)$ на $R_{\text{emp}}(w)$

$$R_{\text{emp}}(w) = \frac{1}{N} \sum_{i=1}^N L(d_i, F(x_i, w))$$


2

Пусть w_{emp} минимизирует $R_{\text{emp}}(w)$ в W ,
тогда $R_{\text{emp}}(w)$ равномерно сходится по вероятности к
 $R(w)$ на растущем N .

3 Равномерная сходимость


$$P(\sup | R(w) - R_{\text{emp}}(w) | > \varepsilon) \rightarrow 0, N \rightarrow \infty \quad (12)$$

необходимое и достаточное условие
непротиворечивости принципа минимизации
эмпирического риска.




Выбор классификатора


- 2 параметра
- 5 параметров
- 6 параметров






- 8 параметров




Мечеть Сулеймана



Где остановиться





Для модели с конечным VC.

- Размер выборки
- $N = K/\epsilon (h \log(1/\epsilon) + \log(1/\beta))$


$P(L, g | V_{\text{train}} < \epsilon) > (1 - \delta)$ вероятность ошибки ϵ для алгоритма L на модели g с выборкой V_{train}

Основные положения




1. Множество всех объектов является вероятностным пространством с некоторой неизвестной вероятностной мерой.
2. Обучающие объекты выбираются случайно и независимо согласно этой мере.
3. Фиксируется некоторое *семейство алгоритмов*.
4. Процесс обучения заключается в построении алгоритма, принадлежащего данному семейству, и доставляющего минимум эмпирическому риску на заданной обучающей выборке.
5. Обобщающая способность алгоритма характеризуется вероятностью ошибочной классификации.
6. В общем случае мы не знаем, какой именно алгоритм будет построен в результате обучения.
7. Водится требование *равномерной сходимости* частоты ошибок к вероятности: частота ошибок должна не сильно отклоняться от их вероятности одновременно для всех алгоритмов семейства.
8. Стремление этого отклонения к нулю с ростом длины выборки принимается за определение *обучаемости семейства алгоритмов*.

Основные результаты




- Введены понятия функции роста и ёмкости семейства алгоритмов, характеризующие сложность.
- Количественные оценки, связывающие обобщающую способность алгоритмов с длиной обучающей выборки и сложностью семейства алгоритмов. Эти оценки дают достаточные условия обучаемости.
- Получены необходимые и достаточные условия *равномерной сходимости* частоты к вероятности в терминах энтропии семейства алгоритмов.
- Предложен метод структурной минимизации риска.




Основные ограничения

- **Проблема** статистической теории является завышенность оценок. Непосредственный расчёт показывает, что для надёжного обучения необходимо иметь порядка 10^6 – 10^8 объектов.
- **Причина** завышенности статистических оценок является их чрезмерная общность.



Модификации

- Эффективная емкость
 - Не превосходит VC – измерение
 - учитывает особенности распределения объектов
 - Не учитывает алгоритм и выборку
 - Метод самоограничивающихся алгоритмов
- Отступы (поля - margins) – SVM
 - Альтернативная функция роста – fat-размерность
 - Обучение с максимизацией отступа




Модификации


- Композиции алгоритмов
 - Алгебраический подход к построению корректных алгоритмов
 - Области компетентности
 - Багинг- bagging
 - Бустинг -boosting

Модификации


- Скользящий контроль




Определить тип классификатора




- Вариант 1
 - Линейный
 - Полином 2 степени
 - Комбинация гипербол



- Вариант 2
 - Линейный
 - Полином 2 степени
 - Комбинация гипербол





Литература

- Теория надёжности обучения по прецедентам (курс лекций, К.В.Воронцов)
<http://www.machinelearning.ru/wiki/index.php>
- Хайкин С. Нейрокомпьютеры: полный курс. – М.:Вильямс – 2006
- Математические методы распознавания образов. Курс лекций. МГУ, ВМиК, кафедра «Математические методы прогнозирования» Местецкий Л.М., 2002–2004