







Продуктовые решения

Временные ряды

Проблемы свертки

Признаки по слоям



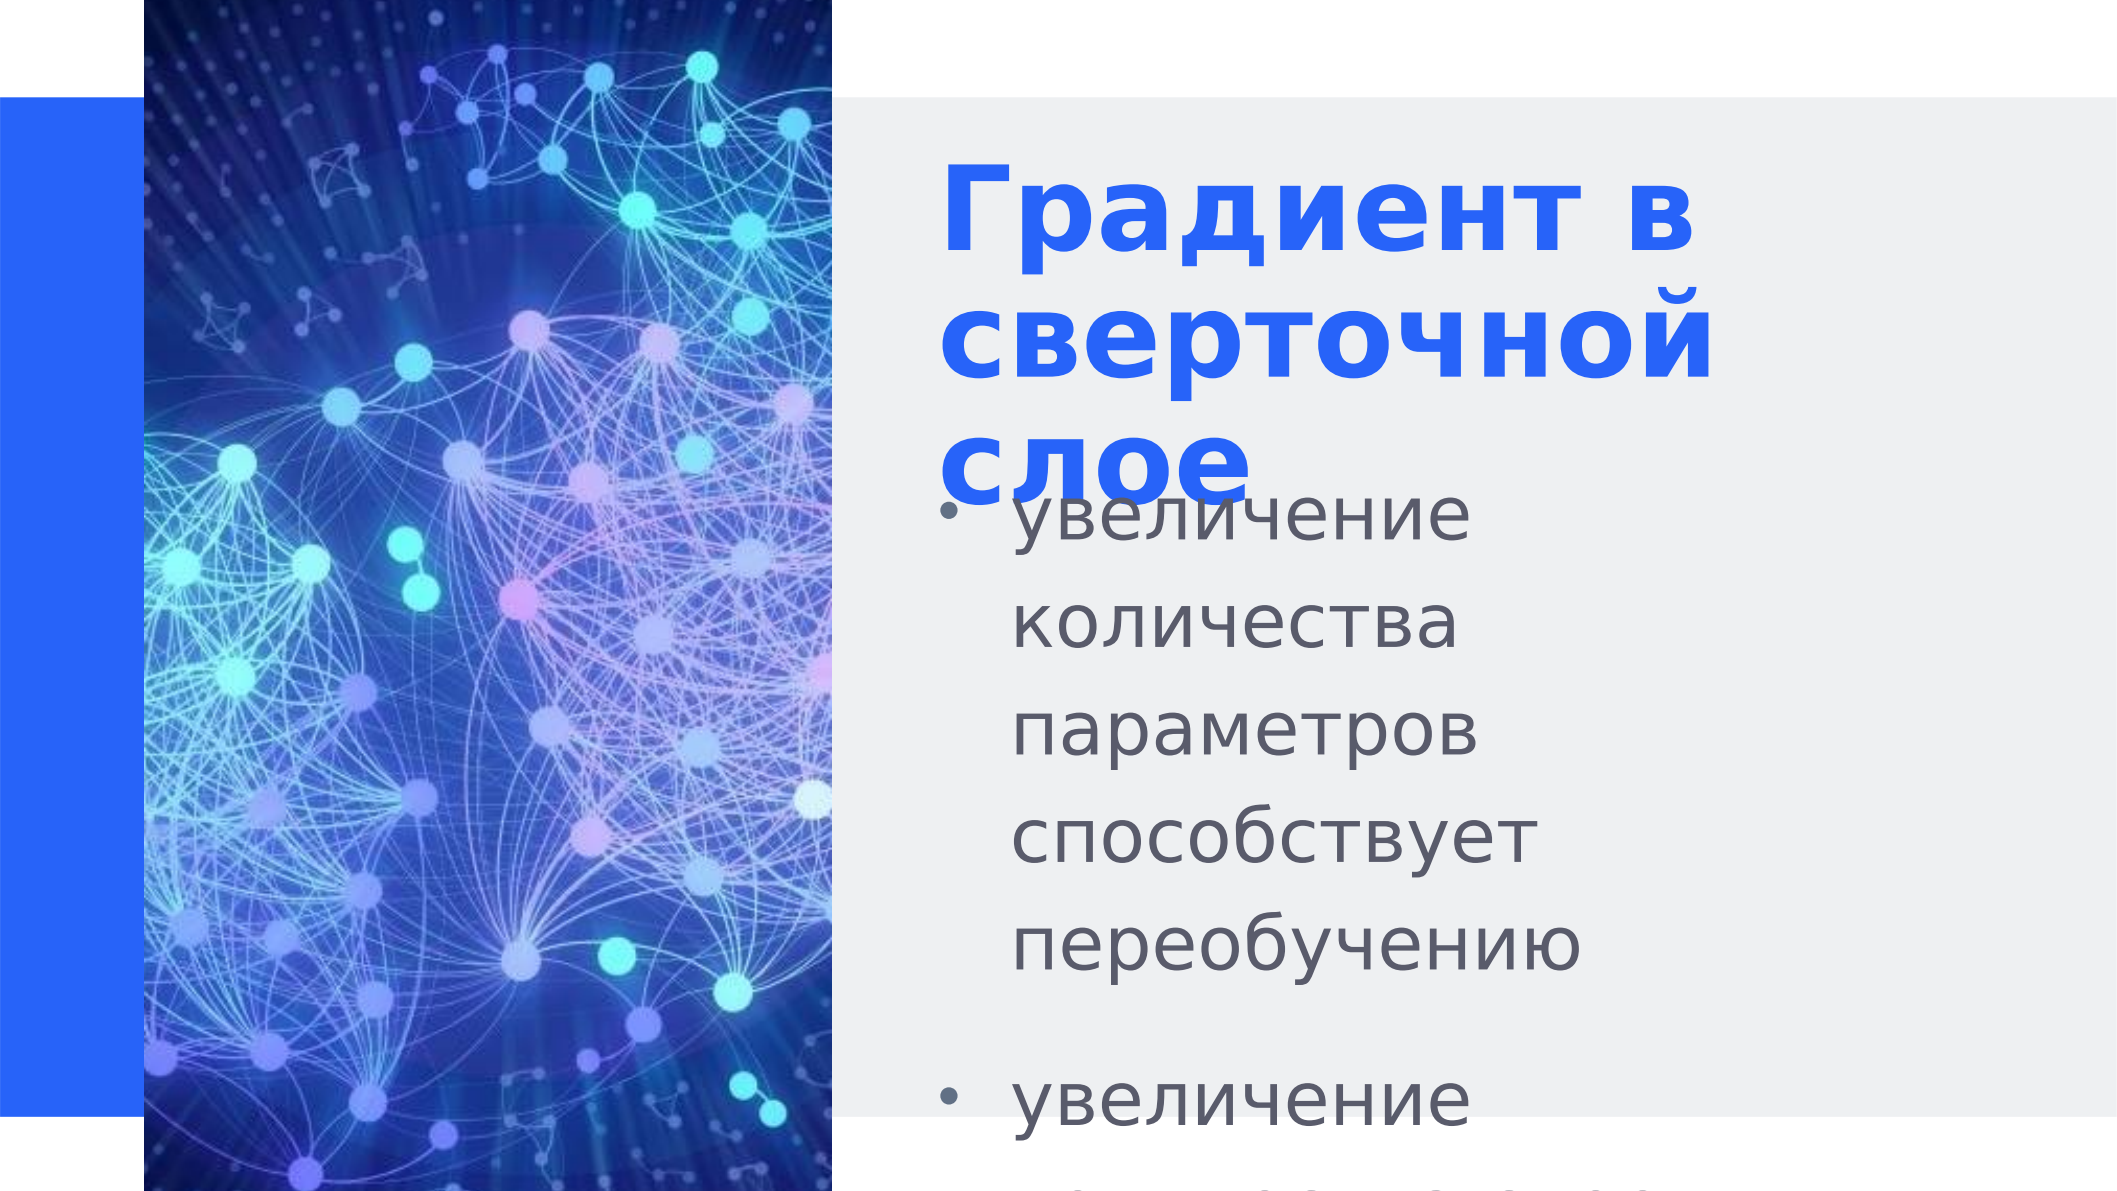
mixed3a, channel



mixed4a, channel



mixed5a, channel




Градиент в сверточной слое

- увеличение количества параметров способствует переобучению
- увеличение

Многослои- ность

добавление слоев
улучшает нижнюю
вариационную
границу
правдоподобия
модели – Хинтон

Исчезновение
(снижение) -





ПРИНЦИПЫ ПОСТРОЕНИЯ СВЕРТОК

01.

Принцип 1

Избегайте representational bottlenecks: не стоит резко снижать размерность представления данных, это нужно делать плавно от начала сети и до классификатора на выходе.



Принцип 2

02.

Высокоразмерные представления следует обрабатывать локально, увеличивая размерность.





03.

Принцип 3

Пространственные сверки можно и нужно факторизовывать на еще более мелкие: это позволит сэкономить ресурсы и пустить их на увеличение размера сети.

Стеки сверток

Свертка 5×5 - 25 параметров.

Стек из 2х слоев со свертками
 3×3 , - $3 \times 3 + 3 \times 3 = 18$
параметров

Свертка 11×11 - 121 параметр

Стек 4-х сверток
 3×3 - - $3 \times 3 + 3 \times 3 + 3 \times 3 + 3$
 $\times 3 = 36$ параметров

04.

Принцип 4

Необходимо соблюдать баланс между глубиной и шириной сети: не стоит резко увеличивать глубину сети отдельно от ширины, и наоборот; следует равномерно увеличивать или уменьшать обе размерности.





СССР pooling

Cascaded Cross Channel
Parameteric pooling.

операция свертки — это
линейное преобразование
патчей изображения



сверточный слой — это
обобщенная линейная
модель (GLM)





Inception, ResNet

Конкатенация признаков


Schematic view (naive version)



Inception



(a) Inception module, naïve version



(b) Inception module with dimension reductions

<https://arxiv.org/abs/1602.07261>

Применение П1

Входная размерность $d \times d \times k$

Нужно получить $\frac{d}{2} \times \frac{d}{2} \times 2k$

Применяем :

свертку из $2k$ фильтров с шагом 1 и пулинг.

Итоговая сложность такой операции .

$$2d^2k^2$$

Пулинг->свертка - $2\left(\frac{d}{2}\right)^2 k^2$ нарушен первый принцип.


Применение П1

Увеличим количество параллельных веток,
Делаем свертки с $S=2$,
Увеличим количество каналов в 2 раза

Репрезентативная сила представления
уменьшается «плавнее».

Для манипулирования глубиной тензора
используются свертки 1×1


Резидуальная функция



$$H(x)$$

$$F(x) = H(x) - x$$

$$F(x) + x = H(x)$$



ResNet




Figure 7. Standard deviations (std) of layer responses on CIFAR-10. The responses are the outputs of each 3×3 layer, after BN and before nonlinearity. **Top:** the layers are shown in their original order. **Bottom:** the responses are ranked in descending order.

Градиент ResNet

$$y_k = h(x_k) + \mathcal{F}(x_k, W_k)$$
$$x_{k+1} = f(y_k)$$

Let $f(x) = x$

$$x_{k+1} = x_k + \mathcal{F}(x_k, W_k) \Rightarrow$$
$$x_K = x_k + \sum_{i=k}^{K-1} \mathcal{F}(x_i, W_i) \Rightarrow$$
$$\frac{\partial E}{\partial x_k} = \frac{\partial E}{\partial x_K} \frac{\partial x_K}{\partial x_k}$$
$$= \frac{\partial E}{\partial x_K} \cdot \left(1 + \frac{\partial}{\partial x_k} \sum_{i=k}^{K-1} \mathcal{F}(x_i, W_i) \right)$$

Let $f(x) = \lambda \cdot x$

$$x_{k+1} = \lambda_k x_k + \mathcal{F}(x_k, W_k) \Rightarrow$$
$$x_K = x_k \prod_{i=k}^K \lambda_i + \sum_{i=k}^{K-1} \hat{\mathcal{F}}(x_i, W_i) \Rightarrow$$
$$\frac{\partial E}{\partial x_k} = \frac{\partial E}{\partial x_K} \frac{\partial x_K}{\partial x_k}$$
$$= \frac{\partial E}{\partial x_K} \cdot \left(\prod_{i=k}^K \lambda_i + \frac{\partial}{\partial x_k} \sum_{i=k}^{K-1} \hat{\mathcal{F}}(x_i, W_i) \right)$$

Градиент ResNet

распределение абсолютных значений градиента, полученных из подсетей разной длины.





Figure 6: How much gradient do the paths of different lengths contribute in a residual network? To find out, we first show the distribution of all possible path lengths (a). This follows a Binomial distribution. Second, we record how much gradient is induced on the first layer of the network through paths of varying length (b), which appears to decay roughly exponentially with the number of modules the gradient passes through. Finally, we can multiply these two functions (c) to show how much gradient comes from all paths of a certain length. Though there are many paths of medium length, paths longer than ~ 20 modules are generally too long to contribute noticeable gradient during training. This suggests that residual networks are large ensembles of short networks.

Градиент ResNet


слой сети K

$$\frac{\partial}{\partial x_k} \sum_{i=k}^{K-1} \mathcal{F}(x_i, W_i)$$


<https://arxiv.org/pdf/1603.05027.pdf>




(a) original




(b) constant scaling




(c) exclusive gating



(d) shortcut-only gating




(e) conv shortcut




(f) dropout shortcut

ResNet




ResNet - ансамбль



(a) Conventional 3-block residual network

=



(b) Unraveled view of (a)

$$\begin{aligned} y_3 &= y_2 + f_3(y_2) \\ &= y_1 + f_2(y_1) + f_3(y_1 + f_2(y_1)) \\ &= y_0 + f_1(y_0) + f_2(y_0 + f_1(y_0)) + f_3(y_0 + f_1(y_0) + f_2(y_0 + f_1(y_0))) \end{aligned}$$

ТРАДИЦИОННЫЕ ТЕХНИКИ



DropOut


$$h(x) = xW + b.$$

$$a(h)$$


$$f(h) = D \odot a(h),$$

$$f(k; p) = \begin{cases} p, & \text{if } k = 1 \\ 1 - p, & \text{if } k = 0 \end{cases},$$


<https://habr.com/ru/company/wunderfund/blog/330814/>



DropOut



<https://habr.com/ru/company/wunderfund/blog/330814/>



DropOut

$$O_i = X_i a\left(\sum_{k=1}^{d_i} w_k x_k + b\right) = \begin{cases} a(\sum_{k=1}^{d_i} w_k x_k + b), & \text{if } X_i = 1 \\ 0, & \text{if } X_i = 0 \end{cases},$$

$$P(X_i = 0) = p.$$

Прямой

На этапе обучения: $O_i = X_i a(\sum_{k=1}^{d_i} w_k x_k + b)$,


На этапе тестирования: $O_i = qa(\sum_{k=1}^{d_i} w_k x_k + b)$

Обратный

На этапе обучения: $O_i = \frac{1}{q} X_i a(\sum_{k=1}^{d_i} w_k x_k + b)$,

На этапе тестирования: $O_i = a(\sum_{k=1}^{d_i} w_k x_k + b)$

Не уменьшает число
параметров!!!




DropOut

На этапе обучения: $O_i = \frac{1}{q} X_i a(\sum_{k=1}^{d_i} w_k x_k + b)$,

На этапе тестирования: $O_i = a(\sum_{k=1}^{d_i} w_k x_k + b)$

$$L = \frac{1}{2} \left(y_{true} - \frac{1}{q} X_i \cdot \alpha \left(\sum_{k=1}^{d_i} w_{kj} x_k \right) \right)^2$$

Не уменьшает число
параметров!!!



Аугментация




Аугментация

Типы ошибок аугментации:


- Ошибки на нецентрированных изображениях.
- Ошибки на повернутых изображениях.
- Ошибки на изображениях с линиями.
- Ошибки на изображениях с

бликами

ReLU: особенности





- Биологическая правдоподобность: односторонняя.
- Разреженная активация: в случайно инициализированной сети активируется только около 50% скрытых блоков (имеют ненулевой выход).
- Лучшее распространение градиента: меньше проблем исчезающего градиента
- Эффективное вычисление: только сравнение, сложение и умножение.
- Масштабно-инвариантный:




Автоэнкодер

- шумоподавление данных
- уменьшение размерности




Слой

```
Conv2DTranspose(64, (2, 2),  
strides=(2, 2), padding='same',  
activation='relu')
```




Обработка МНИСТ


- Исходный Y




зашумленный X




рез y -pred



Сегментация




SegNet



Работает!






Loss: Дице

$$DSC = \frac{2|X \cap Y|}{|X| + |Y|}$$


Сеть UNet



детекторы



GeekBrains



Объекты

Сегменты

Рамки