




ГЕНЕРАТИВНЫЕ МОДЕЛИ

2024 МГТУ

Корлякова М.О



Общие сведения о генеративных моделях.



Общие сведения о генеративных моделях.

- Предполагается, что имеется набор данных, содержащий
- множество примеров сущностей, которые требуется генерировать, – тренировочный набор данных (training dataset)
- Наблюдение (observation) – отдельный элемент тренировочного набора данных
- В задаче генерации изображений каждое наблюдение состоит
- из множества признаков, как правило, признак – значение
- интенсивности отдельного пикселя
- Модель обучается генерировать данные (изображения)
- по тем же правилам, что построен тренировочный набор
- данных
- В процессе генерации каждому пикселю назначается некоторое значение интенсивности

Общие сведения о генеративных моделях.

- Генеративная модель должна быть вероятностной
- Если модель в процессе сэмплирования, например, в качестве значения интенсивности пикселя выдает среднее значение по тренировочной выборке, то модель не является генеративной, поскольку обеспечивает всегда одинаковый результат
- Модель должна включать элемент случайности, отражающий индивидуальные особенности сгенерированного примера
- Таким образом, должно существовать вероятностное
- распределение, которое объясняет, почему некоторые
- наблюдения (изображения) похожи в тренировочном
- наборе, а другие – нет
- **Цель – построить модель, наилучшим образом**
- **имитирующую это распределение**

Генеративные / дискриминативные модели

Разные цели моделирования:


- **Генеративные модели оценивают $p(x, y)$** – совместное распределение вероятностей (оценивают границы классов)
 - Если набор данных не размечен (решается задача обучения без учителя), то модели оценивают $p(x)$ – вероятность увидеть наблюдение x
 - Если тренировочный набор размечен, то генеративная модель может оценивать условную вероятность $p(y|x)$ (вычисляется по правилу Байеса) – вероятность увидеть наблюдение x при условии, что известна его принадлежность классу y
- **Дискриминативные модели оценивают $p(y|x)$** – вероятность метки y при условии, что на входе имеется наблюдение x (оценивают границу между классами)

* Ng A.Y., Jordan M.I. On Discriminative vs. Generative Classifiers: A comparison of logistic regression and naïve Bayes // Advances in Neural Information Processing Systems. – 2002. – [<http://ai.stanford.edu/~ang/papers/nips01-discriminativegenerative.pdf>].


Автоэнкодеры



Автоэнкодер




- шумоподавление данных
- уменьшение размерности




Слой

```
Conv2DTranspose(64, (2, 2),  
strides=(2, 2), padding='same',  
activation='relu')
```




Обработка МНИСТ


- Исходный Y



зашумленный X



рез y -pred





РСА

Из R^m в R^n и в R^m


Автоэнкодер:

- латентное пространство = non-linear РСА

Сегментация




SegNet



Работает!




Сеть UNet



Loss: Дице

$$DSC = \frac{2|X \cap Y|}{|X| + |Y|}$$




Варианты

- FCN
 - SegNet
 - LinkNet
 - PSPNet
 - FPN
 - Unet+
 -
-



VAE

Общие сведения о VAE.



Общие сведения о VAE.

$$Q(Z|X; \theta_1) = N(\mu(X; \theta_1), \Sigma(X; \theta_1))$$



KL Loss

$$\begin{aligned}\text{KL}(q(z) \parallel p(z|x, \theta)) &\triangleq \int q(z) \log \frac{q(z)}{p(z|x, \theta)} \mathbf{d}z \\ &= \int q(z) [\log q(z) - \log p(z|x, \theta)] \mathbf{d}z\end{aligned}$$

$$\begin{aligned}\log p(z|x, \theta) &= \log \left[\frac{p(x|z, \theta)p(z|\theta)}{p(x|\theta)} \right] && \text{По Байесу} \\ &= \log p(x|z, \theta) + \log p(z|\theta) - \log p(x|\theta)\end{aligned}$$

$$\begin{aligned}\text{KL}(q(z) \parallel p(z|x, \theta)) &= \int q(z) [\log q(z) - \log p(z|x, \theta)] \mathbf{d}z \\ &= \int q(z) [\log q(z) - \log p(x|z, \theta) - \log p(z|\theta) + \log p(x|\theta)] \mathbf{d}z\end{aligned}$$

KL Loss

т. к. не зависит от z и $\int q(z)dz = 1$

$$\begin{aligned} & \int q(z) [\log q(z) - \log p(x|z, \theta) - \log p(z|\theta) + \log p(x|\theta)] \mathbf{d}z \\ &= \int q(z) [\log q(z) - \log p(x|z, \theta) - \log p(z|\theta)] \mathbf{d}z + \log p(x|\theta) \\ &= \int q(z) \log \left[\frac{q(z)}{p(x|z, \theta)p(z, \theta)} \right] \mathbf{d}z + \log p(x|\theta) \\ &= \int q(z) \log \left[\frac{q(z)}{p(x, z | \theta)} \right] \mathbf{d}z + \log p(x|\theta) \end{aligned}$$

$$\text{KL}(q(z) \parallel p(z|x, \theta)) = \text{KL}(q(z) \parallel p(x, z | \theta)) + \log p(x|\theta)$$

KL Loss

$$\text{KL}(q(z) || p(z|x, \theta)) = \text{KL}(q(z) || p(x, z | \theta)) + \log p(x|\theta)$$

$$\log p(x|\theta) = \text{KL}(q(z) || p(z|x, \theta)) - \text{KL}(q(z) || p(x, z | \theta))$$


evidence lower bound (ELBO)

$$\mathcal{L}(q, \theta) \triangleq -\text{KL}(q(z) || p(x, z | \theta))$$


$$\log p(x|\theta) = \text{KL}(q(z) || p(z|x, \theta)) + \mathcal{L}(q, \theta)$$

$$\mathcal{L}(q, \theta) = \log p(x|\theta) - \text{KL}(q(z) || p(z|x, \theta))$$

$$\text{KL}(q(z) || p(z|x, \theta)) \geq 0, \mathcal{L}(q, \theta)$$



Общие сведения о VAE.



Факторный Анализ


Из R^m в R^n и в R^m

VAE:

- латентное пространство = FA


Генеративные модели

Общие сведения о GAN.



A small bird with a black head and wings and features grey wings


256x256
Stage-I GAN
without CA




256x256
Stage-I GAN
with CA




256x256
StackGAN
with CA,
Text twice



This bird is completely red with black wings and pointy beak



Архитектура GAN




a)



b)



c)





d)

Noise $\sim N(0,1)$




Generative
Model



https://colab.research.google.com/github/keras-team/keras-io/blob/master/examples/generative/ipynb/dcgan_overriding_train_step.ipynb

Архитектура GAN



Обозначения:

- X – множество наблюдений из распределения p_{data}
- Z – пространство латентных факторов из распределения p_Z (например, множество случайных векторов из равномерного распределения на отрезке $0; 1$)


Генератор

- Отображение $G: Z \rightarrow \mathbb{R}^n$ с параметрами θ
- Цель G – сгенерировать образец, максимальное похожий на наблюдения из распределения p_{data}

Дискриминатор

- Отображение $D: \mathbb{R}^n \rightarrow 0; 1$ с параметрами γ
- Цель D – выдавать максимальную оценку на наблюдениях из X и минимальную оценку на образцах, сгенерированных G

Архитектура GAN




Обозначения:

– θ и γ – параметры нейронных сетей, соответствующих генератору и дискриминатору
– p_{gen} – распределение образцов, порождаемое генератором

Задача – построить распределение p_{gen} , которое наилучшим образом описывает распределение p_{data}



Архитектура GAN



❑ **Функция ошибки:**



$$E_{x \sim p_{data}} [\log D(x)] + E_{\tilde{x} \sim p_{gen}} [\log(1 - D(\tilde{x}))],$$

где $E_{\tilde{x} \sim p_{gen}} [\log(1 - D(\tilde{x}))] = E_{z \sim p_z} [\log(1 - D(G(z)))]$

- ❑ **Задача обучения** генеративной состязательной сети сводится к решению задачи оптимизации (минимаксная игра)

$$\min_G \max_D E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$

Архитектура GAN



Классификация GAN



- Полносвязные генеративные состязательные сети (Fully Connected GANs)
- Условные генеративные состязательные сети (Conditional GANs, CGAN)
- Пирамида Лапласа из состязательных сетей (Laplacian Pyramid of Adversarial Networks, LAPGAN)
- Глубокие сверточные генеративные состязательные сети (Deep Convolutional GANs, DCGAN)
- Генеративные рекуррентные состязательные сети (Generative Recurrent Adversarial Networks, GRAN)
- ...

* Alqahtani H., Kavakli-Thorne M., Kumar G. Applications of Generative Adversarial Networks (GANs): An Updated Review // Archives of Computational Methods in Engineering. – 2019.

Классификация GAN




- Генеративные состязательные сети, максимизирующие информацию (Information Maximizing GANs, InfoGAN)
- Двухнаправленные генеративные состязательные сети (Bidirectional GANs, BiGAN)
- Генеративные автокодировщики (Adversarial Autoencoders, AAE)
- Гибриды вариационных автокодировщиков и генеративных состязательных сетей (Variational Autoencoder-GAN, VAE-GAN)
-

* Alqahtani H., Kavakli-Thorne M., Kumar G. Applications of Generative Adversarial Networks (GANs): An Updated Review // Archives of Computational Methods in Engineering. – 2019.



Пирамиды Лапласа




Pix2Pix



GeekBrains


Input Image



Ground Truth



Predicted Image




https://www.tensorflow.org/tutorials/generative/pix2pix#define_the_loss_functions_and_the_optimizer



GeekBrains

Архитектура CycleGAN





Примеры архитектур

Увеличение количества данных (data augmentation) – генерация синтетических данных, похожих на данные в некоторой существующей выборке, но содержащих различные трансформации, с целью их последующего использования, как правило, для расширения тренировочного набора данных



CycleGAN [<https://www.nature.com/articles/s41598-019-52737-x>] (2019) – задача сегментации данных компьютерного томографии



Data Augmentation GAN (DAGAN) [<https://arxiv.org/pdf/1711.04340.pdf>] (2018) – увеличение количества данных за счет трансформаций



Balancing GAN (BAGAN) [<https://arxiv.org/pdf/1803.09655.pdf>] (2018) – восстановление сбалансированности набора данных

Примеры архитектур




Laplacian Pyramid of Adversarial Networks (LAPGAN)
[<https://arxiv.org/pdf/1506.05751.pdf>] (2015) – повышение разрешения изображений

Generative Adversarial What-Where Network (GAWWN)
[<https://arxiv.org/pdf/1610.02454.pdf>] (2016) – генерация изображений с использованием дополнительного описания и информации о расположении объектов


Generative Adversarial Network for image Super-Resolution (SRGAN) [<https://arxiv.org/pdf/1609.04802.pdf>] (2017) – повышение разрешения изображения

Self-Attention Generative Adversarial Network (SAGAN)
[<https://arxiv.org/pdf/1805.08318.pdf>] (2019) – моделирование зависимостей между отдельными частями изображения для генерации изображений высокого разрешения

StableVTON




IDM-VTON




Техники обучения моделей

Перенос обучения



Техники обучения моделей


Дистилляция



<https://alexanderdyakonov.wordpress.com/2020/10/21/data-distillation/>


Техники обучения моделей

LoRA




Техники обучения моделей

Metric learning



(a) Contrastive [12]



(b) Triplet [39]

<https://habr.com/ru/company/ods/blog/695380/>, <https://arxiv.org/pdf/2105.08149>,
<https://arxiv.org/pdf/2308.00458>, <https://habr.com/ru/companies/ods/articles/695380/>

Техники обучения моделей

SimCLR

Генерации эмбедингов:

- используют сходство, а не класс
- используют аугментацию

<https://arxiv.org/pdf/2002.05709.pdf>

Техники обучения моделей

BYOL





Figure 2: BYOL's architecture. BYOL minimizes a similarity loss between $q_\theta(z_\theta)$ and $sg(z'_\xi)$, where θ are the trained weights, ξ are an exponential moving average of θ and sg means stop-gradient. At the end of training, everything but f_θ is discarded, and y_θ is used as the image representation.

<https://arxiv.org/pdf/2006.07733>

Техники обучения моделей

DINOv2 (Vision Transformer):

Focus on unsupervised learning
to process images




Техники обучения моделей

CLIP

CLIP (Contrastive Language-Image Pretraining):

Combines images and text for multi-modal understanding



Вопросы



GeekBrains

