


2022 Корлякова М.О.

Самоорганизация



Самоорганизация. Свойства




- Глобальный порядок определяется локальными взаимодействиями
- Изменение силы связей ведет к самоусилению системы
- Ограниченное число ресурсов ведет к конкуренции.
- Изменение силы связей ведет к кооперации
- Описание образов избыточно







Гипотеза Компактности

Похожие
объекты близки
друг к другу в
пространстве
признаков



Гипотеза Непрерывности

Близким
объектам
соответствуют
близкие ответы



**Как выглядит
близость:**

Расстояние между объектами

$$\rho(x, x_i) = \left(\sum_{j=1, n} w_j |x^j - x_i^j|^p \right)^{1/p}$$



Меры расстояния

эвклидова мера

$$d(X, W_i) = \|X - W_i\|^2 = \sqrt{\sum_{j=1:N} ((x_j - w_{ij})^2)};$$

скалярное произведение




$$d(X, W_i) = 1 - \langle X, W_i \rangle = 1 - \|X\|^2 * \|W_i\|^2 * \cos(X, W_i);$$

манхэттенское расстояние


$$d(X, W_i) = \sum_{j=1:N} (|x_j - w_{ij}|);$$

suprenum-норма

$$d(X, W_i) = \max_j (|x_j - w_{ij}|).$$



Влияние расстояния:



$$T = \{ (X_i) \}, i = 1, N$$
$$\rho : X \times X \rightarrow [0, \infty)$$

$$Y$$

$$a : X \rightarrow Y$$

Unsupervised Learning:

$$E = \min \sum_{X \in W_k} \frac{1}{|X_{wk}|} \rho(X, W_k)$$

$$E = \max \sum_{W_h, W_k} \rho(W_h, W_k)$$

**Основная идея -
Критерий:**



Области применения:

- Упрощение сложных задач классификации;
- Сокращение объема хранения;
- Выделить нетипичные объекты.


Проблемы:

- Нет точной постановки задачи
- Много критериев
- Много эвристик
- Результат зависит от метрики



Обучение как восстановление распределения

Смесь распределений



Смесь распределений

Задача 1: имея простую выборку $X^m \sim p(x)$ и зная k , оценить вектор параметров $\Theta = (w_1, \dots, w_k, \theta_1, \dots, \theta_k)$.

Задача 2: оценить ещё и k .

Задача максимизации логарифма правдоподобия

$$L(\Theta) = \ln \prod_{i=1}^m p(x_i) = \sum_{i=1}^m \ln \sum_{j=1}^k w_j p_j(x_i; \theta_j) \rightarrow \max_{\Theta}$$

при ограничениях $\sum_{j=1}^k w_j = 1; \quad w_j \geq 0.$

Смесь распределений

$$Q(\Theta) = \ln \prod_{i=1}^m p(x_i) = \sum_{i=1}^m \ln \sum_{j=1}^k w_j p_j(x_i) \rightarrow \max_{\Theta} \quad \sum_{j=1}^k w_j = 1$$

$$L(\Theta; X^m) = \sum_{i=1}^m \ln \left(\sum_{j=1}^k w_j p_j(x_i) \right) - \lambda \left(\sum_{j=1}^k w_j - 1 \right)$$

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^m \frac{p_j(x_i)}{\sum_{s=1}^k w_s p_s(x_i)} - \lambda = 0, \quad j = 1, \dots, k$$

Умножим левую и правую части на w_j , просуммируем все k этих равенств, и поменяем местами знаки суммирования по j и по i :

$$\sum_{i=1}^m \sum_{j=1}^k \underbrace{\frac{w_j p_j(x_i)}{\sum_{s=1}^k w_s p_s(x_i)}}_{=1} = \lambda \sum_{j=1}^k \underbrace{w_j}_{=1}, \quad \Rightarrow \quad \lambda = m$$

Смесь распределений

$$w_j = \frac{1}{m} \sum_{i=1}^m \frac{w_j p_j(x_i)}{\sum_{s=1}^k w_s p_s(x_i)} = \frac{1}{m} \sum_{i=1}^m g_{ij}, \quad j = 1, \dots, k$$

где $g_{ij} = \frac{w_j p_j(x_i)}{\sum_{s=1}^k w_s p_s(x_i)}$

“похожи” на вероятности того, что x_i попал в j -тое скопление смеси:

$$g_{ij} = P(j|x_i) = \frac{P(j)p(x_i|j)}{p(x_i)} = \frac{w_j p_j(x_i; \theta_j)}{p(x_i)} = \frac{w_j p_j(x_i; \theta_j)}{\sum_{s=1}^k w_s p_s(x_i; \theta_s)}$$

$$\sum_{j=1}^k g_{ij} = 1$$

Смесь распределений

Приравняем к нулю производную лагранжиана по θ_j , помня, что $p_j(x) = \varphi(x; \theta_j)$:

$$\begin{aligned}\frac{\partial L}{\partial \theta_j} &= \sum_{i=1}^m \frac{w_j}{\sum_{s=1}^k w_s p_s(x_i)} \frac{\partial}{\partial \theta_j} p_j(x_i) = \sum_{i=1}^m \frac{w_j p_j(x_i)}{\sum_{s=1}^k w_s p_s(x_i)} \frac{\partial}{\partial \theta_j} \ln p_j(x_i) = \\ &= \sum_{i=1}^m g_{ij} \frac{\partial}{\partial \theta_j} \ln p_j(x_i) = \frac{\partial}{\partial \theta_j} \sum_{i=1}^m g_{ij} \ln p_j(x_i) = 0, \quad j = 1, \dots, k.\end{aligned}$$


Полученное условие совпадает с необходимым условием максимума в задаче максимизации взвешенного правдоподобия:

$$\theta_j := \arg \max_{\theta} \sum_{i=1}^m g_{ij} \ln \varphi(x_i; \theta), \quad j = 1, \dots, k.$$

при условии, что g_{ij} не зависят от θ . Что, конечно же, не так.

Максимизация логарифма
правдоподобия

$$L(w, q) = \ln \prod_{i=1, N} p(X_i) = \sum_{i=1, N} \ln \sum_{j=1, K} w_j F(X_i, q_j)$$



ЕМ-алгоритм

Начальное приближение

Цикл:

1. Expectation


Оценка скрытых переменных

$$G=(g_{ij}), g_{ij}=P(j|x_i)$$

2. Maximization

максимизация правдоподобия
по отдельным компонентам
(w,q)

3. Stop-condition – пока нет
стабилизации



ЕМ-алгоритм

ЕМ-алгоритм


Максимизация логарифма
правдоподобия

$$\ln P(X) = \sum_{i=1, N} \ln \left(\sum_{j=1, K} w_j F(X_i, q_j) \right)$$

$$g_i(j) = P(j | X_i)$$

$$\ln P(X) = \sum_{i=1, N} \ln \left(\sum_{j=1, K} \frac{g_i(j)}{g_i(j)} w_j F(X_i, q_j) \right)$$

$$\sum_{i=1, N} \ln \left(\sum_{j=1, K} \frac{g_i(j)}{g_i(j)} w_j F(X_i, q_j) \right) \geq \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln \left(\frac{1}{g_i(j)} w_j F(X_i, q_j) \right)$$



Е-шаг:
$$L = \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln \left(\frac{1}{g_i(j)} w_j F(X_i, q_j) \right)$$

ЕМ-алгорит


$$L = \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln \left(\frac{1}{g_i(j)} w_j F(X_i, q_j) \right)$$

$$\ln P(X) - L(w, q) = \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln \left(\frac{P(X_i) g_i(j)}{w_j F(X_i, q_j)} \right)$$

$$P(j | X_i) = \left(\frac{P(X_i)}{w_j F(X_i, q_j)} \right)^{-1}$$

$$\ln P(X) - L(w, q) = \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln \left(\frac{g_i(j)}{P(j | X_i)} \right)$$

$$\ln P(X) - L(w, q) = \sum_{i=1, N} E_{g_i(j)} \left[\left(\frac{g_i(j)}{P(j | X_i)} \right) \right] = \sum_{i=1, N} KL(g_i(j) \| P(j | X_i))$$



Е-шаг: $g_i(j) = P(j | X_i) = \left(\frac{P(X_i)}{w_j F(X_i, q_j)} \right)^{-1}$


ЕМ-алгорит

Оптимизация w, q

$$L = \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln \left(\frac{1}{g_i(j)} w_j F(X_i, q_j) \right)$$

$$L = \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln(w_j F(X_i, q_j)) - \sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln(g_i(j))$$

$$\max_{w, q} \left(\sum_{i=1, N} \sum_{j=1, K} g_i(j) \ln(w_j F(X_i, q_j)) \right)$$



М-шаг:


$$w_j = \frac{1}{N} \sum_{i=1, N} g_i(j)$$

$$q = \arg \max \sum_{i=1, N} g_i(j) \ln(F(X_i, q_j))$$




Реализация обучения без учителя

K-means




Пример

Исходное множество



Результат



Алгоритм к-средних

1. Номер итерации $s=0$
2. Связать с каждым кластером K_j объект X_i из обучающей выборки (случайно).
3. если число кластеров меньше N , то перейти к процедуре формирования кластеров (п.4.).
4. Вычислить расстояния от всех объектов до всех центров кластеров.
5. присоединить объект X_i к кластеру S_k , если
6. повторить для всех объектов выборки.
7. вычислить новое положение центров кластеров
8. где N_b – число примеров множества S_b .
9. Повторять от п.4. пока кластер смещается более чем на ↗
(задано пользователем), иначе остановить процесс.



Достоинства алгоритма k- средних:

- простота использования;
- быстрота использования;
- понятность и прозрачность алгоритма.

Недостатки алгоритма k- средних:

- Чувствителен к выбросам, которые могут исказить среднее
- Может медленно работать на больших базах данных




Принцип

Обучение. Самоорганизация на основе конкуренции.

Обобщение. Ближайший нейрон

Использует специальные функции преобразования для разложения входного образа.

SOM – Self-Organizing Maps




Нейрон WTA

Победитель получает все.

Winner Take All

$$w_{ij}(t+1) = w_{ij}(t) + \eta \cdot (x_j^k - w_{ij}(t)).$$




Модель сети Кохонена

Сеть Кохонена - Алгоритм векторного кодирования.

Реализует топологическое отображение, которое оптимально размещает фиксированное количество векторов в входном пространстве высокой размерности.

Архитектура сети SOM Кохонена





Модель сети Кохонена

Один слой.

Нейроны Кохонена (РБФ).

Горизонтальные связи.

Обратных связей нет.

Обучение без учителя.

Обучение по алгоритмам соревнования.

Задача – кластеризация.

Число входов = размеру образца.

Число выходов = числу нейронов.


Минимизация погрешности квантования

$$E_q = \frac{1}{p} \cdot \sum_{k=1}^p d(X^k, W_{w(k)}),$$

Цель обучения

Формирование сети Кохонена

- Инициализация
- Конкуренция (выбор нейрона победителя)
- Кооперация (для победителя найти его окрестность)
- Синаптическая адаптация (изменяем победителя и его окрестность)



Конкуренция

$$I(x) = \arg \min || X - W_j ||, \quad j=1, \dots, p$$

p - число нейронов



Кооперация

Латеральное взаимодействие

h_{ji} – топологическая окрестность с центром в i .

d_{ji} – латеральное расстояние от нейрона i к нейрону j

($d_{ji}^2 = ||r_j - r_i||^2$, r_i – позиция нейрона i)

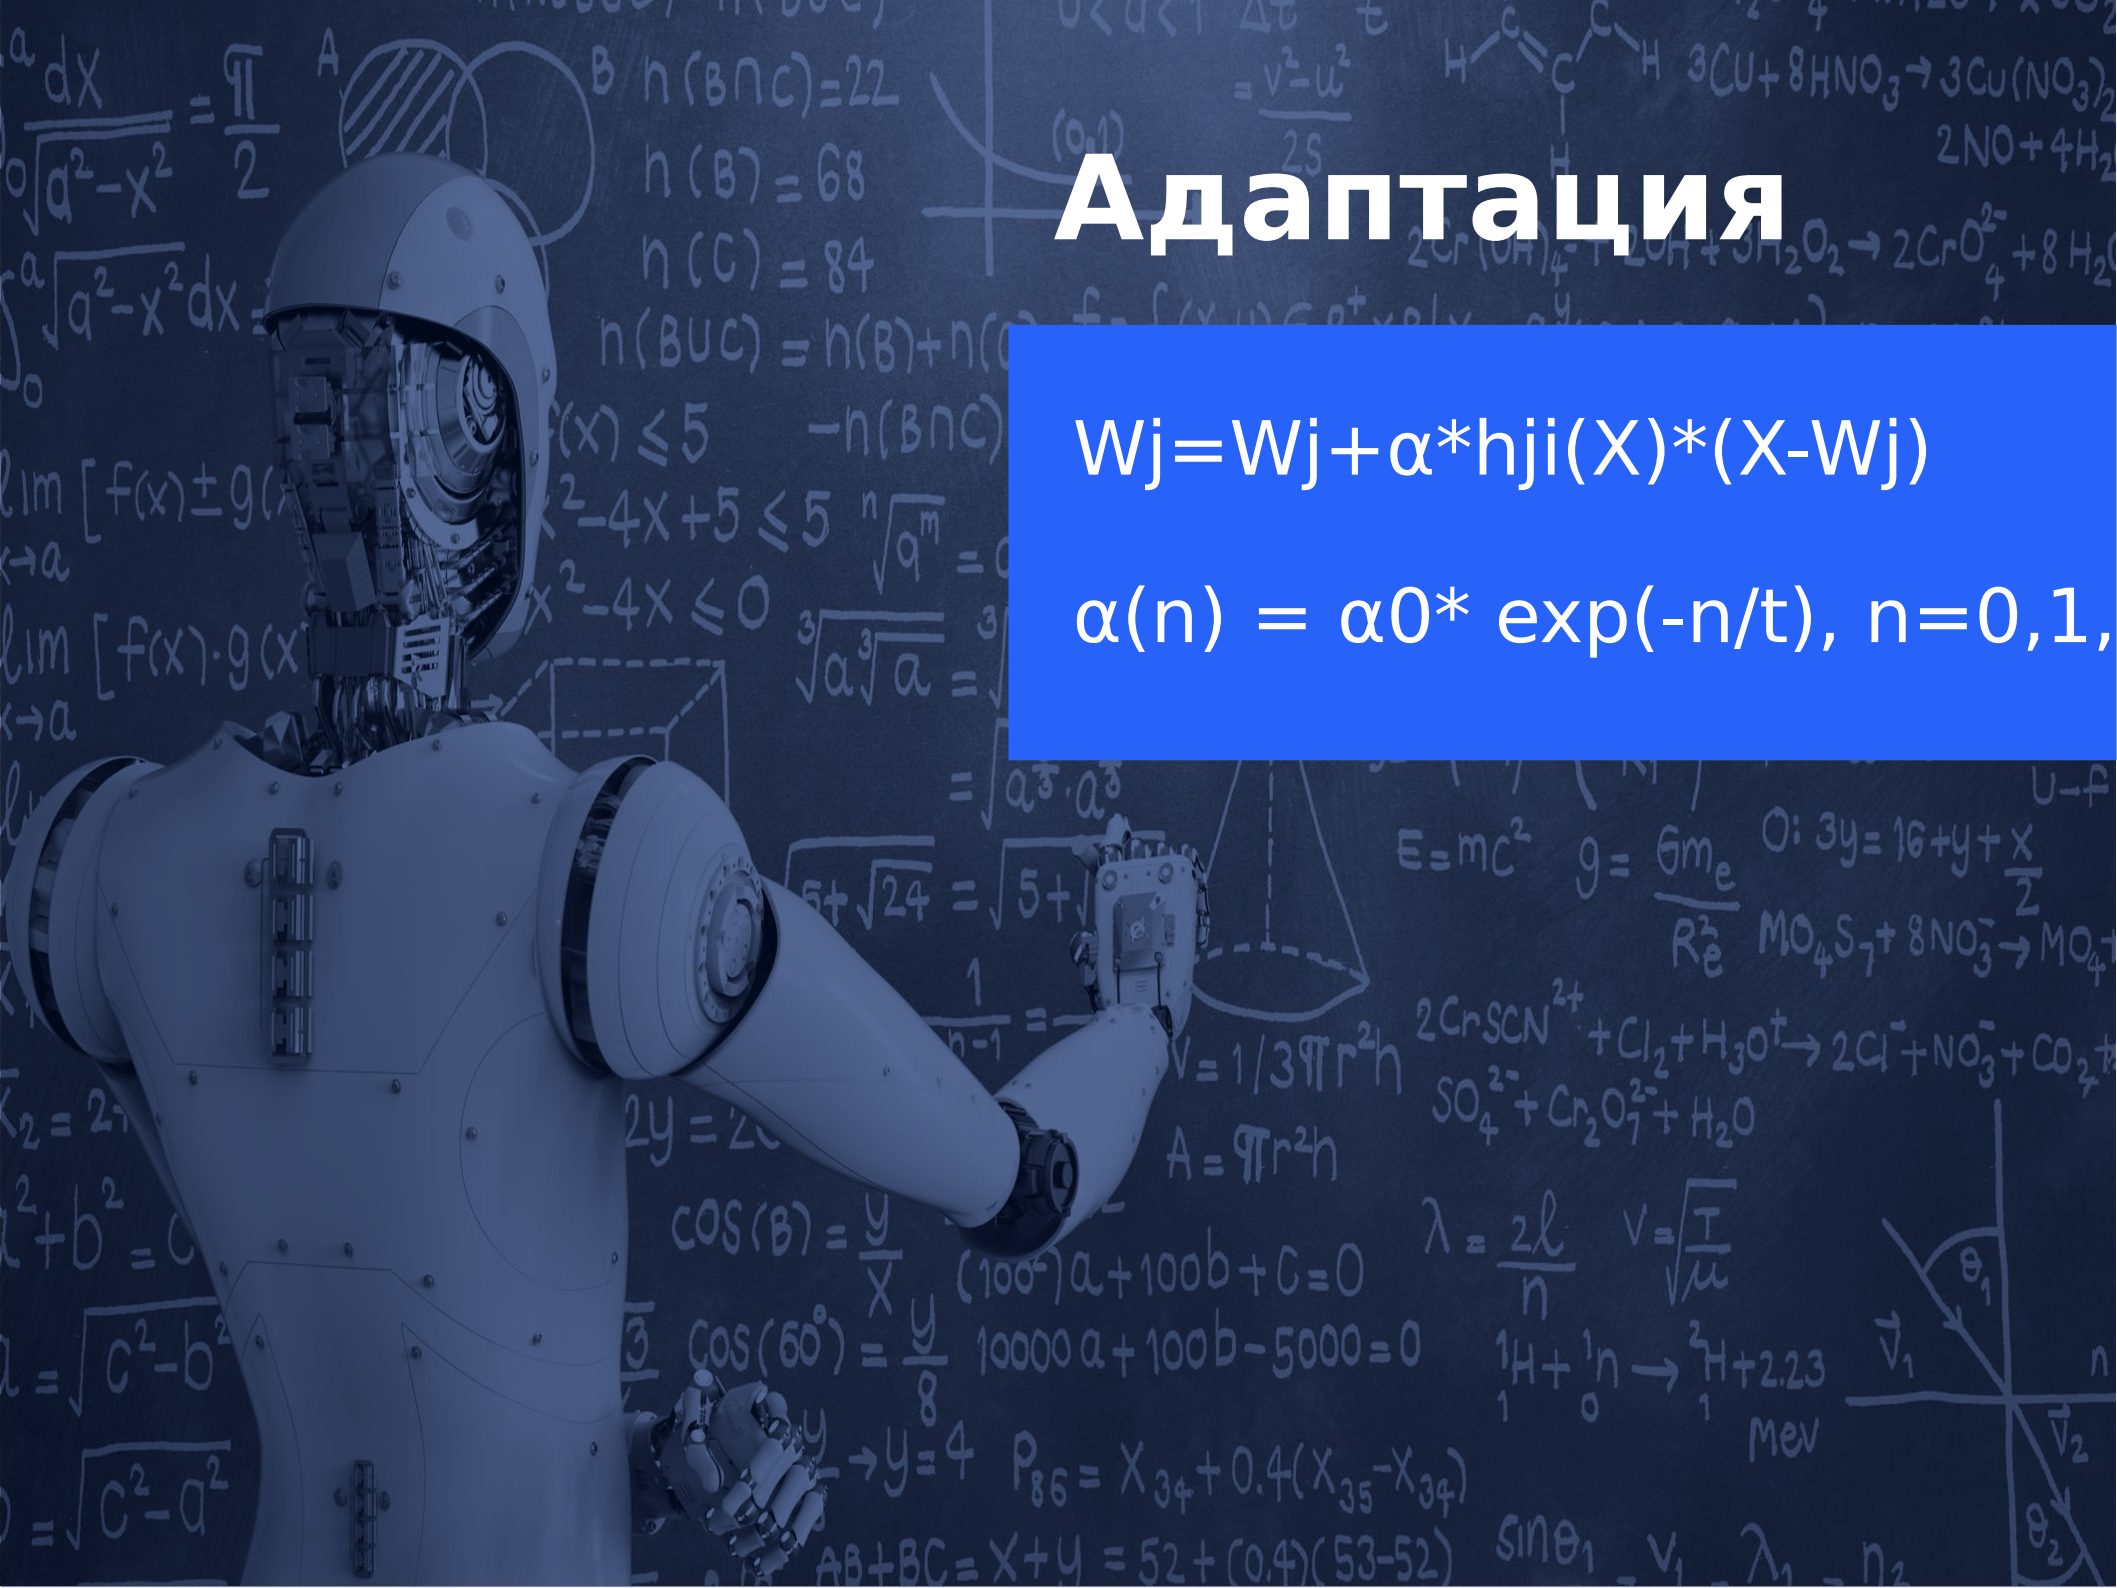
$h_{ji}(X) = \exp(-d_{ji}^2 / (2 * g^2))$

g -эффективная ширина топологической окрестности


Адаптация

$$W_j = W_j + \alpha * h_{ji}(X) * (X - W_j)$$



$$\alpha(n) = \alpha_0 * \exp(-n/t), n=0,1,$$



Двухмерная сеть




Развитие сети SOM




Число эпох самоорганизации


10



20



30





RBM Restricted Boltzmann machine

Идея RBM


1. Хопфилд $E = -\frac{1}{2} \sum_{ij} w_{ij} s_i s_j + \sum_i b_i s_i$

2. Обыкновенная Машина Больцмана

$$E = - \sum_{i < j} w_{ij} s_i s_j - \sum_i b_i s_i$$

3. Ограниченная Машина Больцмана

$$E(v, h) = - \sum_i^n a_i v_i - \sum_j^m b_j h_j - \sum_i^n \sum_j^m w_{ij} v_i h_j$$




Идея RBM

$$E(v, h) = - \sum_i^n a_i v_i - \sum_j^m b_j h_j - \sum_i^n \sum_j^m w_{ij} v_i h_j$$

$$p(v, h) = \frac{1}{Z} e^{-E(v, h)}$$

$$Z = \sum_r^N \sum_t^M e^{-E(v^{(r)}, h^{(t)})}$$


$$p(v) = \sum_t^M P(v, h^{(t)}) = \frac{1}{Z} \sum_t^M e^{-E(v, h^{(t)})}$$



Идея RBM

$$P(h_k = 1|v) = \frac{e^{-E_1}}{e^{-E_1} + e^{-E_0}} = \frac{1}{1 + e^{E_1 - E_0}} = \frac{1}{1 + e^{-b - \sum_i^n v_i w_{ik}}} = \sigma \left(-b - \sum_i^n v_i w_{ik} \right)$$

$$P(h|v) = \prod_j^m P(h_j|v)$$



Идея RBM

$$\frac{\partial \ln P(v^{(k)})}{\partial w_{ij}} = \frac{1}{P(v^{(k)})} \frac{\partial P(v^{(k)})}{\partial w_{ij}}$$

$$f(E(v, h^{(t)})) = e^{-E(v, h^{(t)})}$$

$$\hat{E} = E(v, h^{(t)})$$

$$P(v) = \frac{f(\hat{E})}{Z}$$

$$\frac{\partial P(v^{(k)})}{\partial w_{ij}} = \frac{Z \cdot \frac{\partial f(\hat{E})}{\partial w_{ij}} - \frac{\partial Z}{\partial w_{ij}} \cdot f(\hat{E})}{Z^2}$$

$$\frac{\partial f(\hat{E})}{\partial w_{ij}} = \frac{\partial f(\hat{E})}{\partial \hat{E}} \frac{\partial \hat{E}}{\partial w_{ij}}$$


$$\frac{\partial Z}{\partial w_{ij}} = \frac{\partial Z}{\partial \hat{E}} \frac{\partial \hat{E}}{\partial w_{ij}}$$

$$p(v) = \sum_t^M P(v, h^{(t)}) = \frac{1}{Z} \sum_t^M e^{-E(v, h^{(t)})}$$

$$\frac{\partial E(v, h)}{\partial w_{ij}} = -v_i h_j$$

$$\frac{\partial E(v, h)}{\partial a_i} = -v_i$$

$$\frac{\partial E(v, h)}{\partial b_j} = -h_j$$




Идея RBM

$$f(E(v, h^{(t)})) = e^{-E(v, h^{(t)})}, \quad \hat{E} = E(v, h^{(t)}), \quad \frac{\partial f(\hat{E})}{\partial \hat{E}} = -e^{-E(v, h^{(t)})}$$

$$\frac{\partial e^{-E(v, h)}}{\partial w_{ij}} = e^{-E(v, h)} \frac{\partial (-E(v, h))}{\partial w_{ij}} = v_i h_j e^{-E(v, h)}$$

$$\frac{\partial e^{-E(v, h)}}{\partial a_i} = v_i e^{-E(v, h)}$$

$$\frac{\partial e^{-E(v, h)}}{\partial b_j} = h_j e^{-E(v, h)}$$




<https://habr.com/ru/post/159909/>

Идея RBM

$$\frac{\partial Z}{\partial w_{ij}} = \sum_r \sum_t \frac{\partial e^{-E(v^{(r)}, h^{(t)})}}{\partial w_{ij}} = \sum_r \sum_t v_i^{(r)} h_j^{(t)} e^{-E(v^{(r)}, h^{(t)})}$$

$$\frac{\partial Z}{\partial a_i} = \sum_r \sum_t v_i^{(r)} e^{-E(v^{(r)}, h^{(t)})}$$

$$\frac{\partial Z}{\partial b_j} = \sum_r \sum_t h_j^{(t)} e^{-E(v^{(r)}, h^{(t)})}$$



$$\frac{\partial P(v^{(k)})}{\partial w_{ij}} = \frac{1}{Z^2} \left(Z \left(\sum_t v_i^{(k)} h_j^{(t)} e^{-E(v^{(k)}, h^{(t)})} \right) - \left(\sum_t e^{-E(v^{(k)}, h^{(t)})} \right) \left(\sum_r \sum_t v_i^{(r)} h_j^{(t)} e^{-E(v^{(r)}, h^{(t)})} \right) \right)$$


Идея RBM

$$\frac{\partial \ln P(v^{(k)})}{\partial w_{ij}} = \frac{1}{P(v^{(k)})} \frac{\partial P(v^{(k)})}{\partial w_{ij}} \quad |$$

$$\frac{\partial \ln P(v^{(k)})}{\partial w_{ij}} = \frac{Z}{\sum_t^M e^{-E(v^{(k)}, h^{(t)})}} \frac{1}{Z^2} \left(Z \left(\sum_t^M v_i^{(k)} h_j^{(t)} e^{-E(v^{(k)}, h^{(t)})} \right) - \right.$$

$$\left. - \left(\sum_t^M e^{-E(v^{(k)}, h^{(t)})} \right) \left(\sum_r^N \sum_t^M v_i^{(r)} h_j^{(t)} e^{-E(v^{(r)}, h^{(t)})} \right) \right) =$$

$$= \frac{\sum_t^M v_j^{(k)} h_j^{(t)} e^{-E(v^{(k)}, h^{(t)})}}{\sum_t^M e^{-E(v^{(k)}, h^{(t)})}} - P(v^{(k)}) \frac{\sum_r^N \sum_t^M v_i^{(r)} h_j^{(t)} e^{-E(v^{(r)}, h^{(t)})}}{\sum_t^M e^{-E(v^{(k)}, h^{(t)})}} \quad |$$




Идея RBM

$$\frac{\partial \ln P(v^{(k)})}{\partial w_{ij}} = \sum_t v_i^{(k)} h_j^{(t)} P(h^{(t)} | v^{(k)}) - \sum_r \sum_t v_i^{(r)} h_j^{(t)} P(h^{(t)}, v^{(k)})$$

$$\frac{\partial \ln P(v^{(k)})}{\partial w_{ij}} = M [v_i^{(k)} h_j]_{\text{data}} - M [v_i h_j]_{\text{model}}$$

$$\frac{\partial \ln P(v^{(k)})}{\partial a_i} = v_i^{(k)} - \sum_r v_i^{(r)} P(v^{(r)} | h^{(t)}) = v_i^{(k)} - M [v_i]_{\text{model}}$$

$$\frac{\partial \ln P(v^{(k)})}{\partial b_j} = \sum_t h_j^{(t)} P(h^{(t)} | v^{(k)}) - \sum_r \sum_t h_j^{(t)} P(v^{(r)}, h^{(t)}) = M [h_j]_{\text{data}} - M [h_j]_{\text{model}}$$




Идея RBM

$$\frac{\partial \ln P(v^{(k)})}{\partial b_j} = \sum_t h_j^{(t)} P(h^{(t)} | v^{(k)}) - \sum_r \sum_t h_j^{(t)} P(v^{(r)}, h^{(t)}) =$$
$$M[h_j]_{\text{data}} - M[h_j]_{\text{model}}$$

$$\Delta w_{ij} = \eta (M[v_i h_j]_{\text{data}} - M[v_i h_j]_{\text{model}})$$

$$\Delta a_i = \eta (v_i - M[v_i]_{\text{model}})$$

$$\Delta b_j = \eta (M[h_j]_{\text{data}} - M[h_j]_{\text{model}})$$






Обучение Contrastive Divergence

1. состояние видимых нейронов приравнивается к входному образу
2. выводятся вероятности состояний скрытого слоя
3. каждому нейрону скрытого слоя ставится в соответствие состояние «1» с вероятностью, равной его текущему состоянию
4. выводятся вероятности видимого слоя на основании скрытого
5. если текущая итерация меньше k , то возврат к шагу 2
6. выводятся вероятности состояний скрытого слоя

RBM: Схема



$$\Delta w_{ij} = \eta \left(M[v_i h_j]^{(0)} - M[v_i h_j]^{(\infty)} \right)$$



RBM: Приложения

1. Ассоциативная память
2. Самоорганизующиеся модели
3. Формирование скрытых пространств